Informe de Examen Domiciliario de R

Institución: Universidad Torcuato Di Tella
Profesores: Bounos, Ian Evangelos - Dolanyi Plaza, Pedro
Alumno: Martinez Pedro
Legajo: 24Q999

Ejercicio de Análisis de Datos: Dinámica y movimiento en los Precios Internacionales de Commodities

Antes de plantear las preguntas, se realizó un análisis y una limpieza del dataset de precios de productos del FMI. Para poder utilizar correctamente el paquete de tidyverse, el conjunto de datos —originalmente en formato ancho y con valores faltantes codificados como "-"— fue depurado y transformado a formato largo utilizando la herramienta `pivot_longer()` del paquete `tidyr`. Se corroboró la ausencia de anomalías en los datos.

A continuación, se presentan las preguntas de investigación abordadas, su justificación y el análisis de los resultados obtenidos.

Pregunta 1: ¿Cuáles son las correlaciones más importantes entre los niveles de precios de distintos commodities y qué revelan sobre la estructura global de costos?

Analizar cómo se mueven en conjunto los precios de productos de naturaleza muy distinta nos ayuda a entender la transmisión de shocks en la economía global. Si bien es esperable que bienes sustitutos se muevan juntos, investigar correlaciones cruzadas (por ejemplo, entre energía y alimentos) nos revela si los cambios en un mercado se filtran a las demás áreas. Estos son datos que pueden ser de utilidad para países exportadores de cierto producto e importadores de otros, ya que de ello depende el funcionamiento de sus economías.

Se construyó una matriz de correlaciones esquivando los valores faltantes mediante `use = "pairwise.complete.obs"`. Como es una matriz simétrica, podemos tener en cuenta solo una mitad, y también podemos descartar la diagonal (pues la correlación de un producto consigo mismo es uno).

Luego, transformamos el resultado en un dataframe manejable y aplicamos rutinas de `dplyr` para extraer analíticamente las 10 correlaciones más grandes, filtrando explícitamente también pares que cruzaran sectores (industrial vs. agropecuario).

Tabla 1: Top 10 Correlaciones Positivas Más Fuertes

#	Producto 1	Producto 2	Correlación
1	petroleo_general	petroleo_brent	0.9990
2	petroleo_brent	petroleo_dubai	0.9988
3	petroleo_general	petroleo_dubai	0.9984
4	petroleo_general	petroleo_wti	0.9956
5	petroleo_brent	petroleo_wti	0.9918
6	petroleo_dubai	petroleo_wti	0.9900
7	gas_natural_rusia	gas_natural_licuado	0.9775
8	petroleo_general	carbon_sudafrica	0.9645
9	poroto_soja	harina_soja	0.9636
10	petroleo_dubai	carbon_sudafrica	0.9622

Tabla 2: Correlaciones Positivas Entre Sectores Distintos (Inesperadas/Estructurales)

#	Producto 1	Producto 2	Correlación
1	poroto_soja	petroleo_brent	0.8565
2	maiz	petroleo_brent	0.8495
3	maiz	mineral_hierro	0.8410
4	poroto_soja	mineral_hierro	0.8381
5	poroto_soja	cobre	0.8181
6	maiz	cobre	0.8101
7	carne_bovina	mineral_hierro	0.7435
8	carne_bovina	cobre	0.7278
9	carne_bovina	petroleo_brent	0.7137

Tabla 3: Top 10 Correlaciones Negativas (Desacople / Sustitución)

#	Producto 1	Producto 2	Correlación
1	salmon	madera_blanda_aserrada	-0.5067
2	X_id	gas_natural_eeuu	-0.5178
3	tronco_madera_blanda	gas_natural_rusia	-0.5306
4	madera_dura_aserrada	gas_natural_eeuu	-0.5371
5	tronco_madera_blanda	gas_natural_eeuu	-0.5566
6	cerdo	tronco_madera_blanda	-0.5613
7	madera_blanda_aserrada	gas_natural_eeuu	-0.5712
8	cerdo	madera_blanda_aserrada	-0.5836
9	cuero	gas_natural_rusia	-0.6080
10	cuero	gas_natural_eeuu	-0.6616

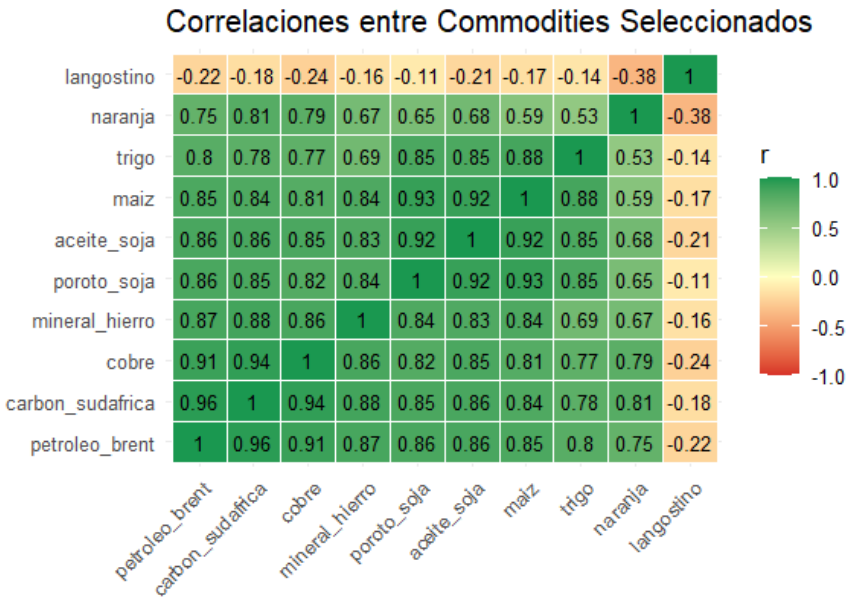


Figura 1: Matriz de correlaciones de los commodities en niveles.

Los resultados muestran correlaciones muy fuertes intrasectoriales (como entre distintos me-

tales industriales, fuertemente atados al ciclo económico global). Sin embargo, lo más sorprendente es la alta correlación entre el petróleo y los commodities agrícolas (soja, maíz). Esto puede llevarnos a la conclusión de que la energía funciona como un insumo crítico en el sector agrícola. Además, las correlaciones negativas demuestran dinámicas de sustitución, o el "aislamiento" de bienes cuyas demandas responden a mercados sumamente desvinculados al resto.

Pregunta 2: ¿Cómo reaccionan los distintos productos ante crisis globales (2001 vs. 2008) y cuáles demuestran mayor variación?

Las recesiones económicas no impactan de igual manera en todos los sectores. Enfocarnos en períodos de crisis nos permite aproximarnos de forma empírica a la elasticidad ingreso de la demanda de distintos bienes (tomando la crisis como un shock a la riqueza agregada). Nos puede ayudar a comprender riesgos para países sumamente dependientes del comercio internacional de ciertos productos.

Dado que buscábamos comparar variaciones y no niveles, primero calculamos la inflación anual de cada producto. Se diseñó una función que filtra los años críticos (2001 y 2009 para captar el impacto de las crisis) y extrae los productos con variaciones más extremas.

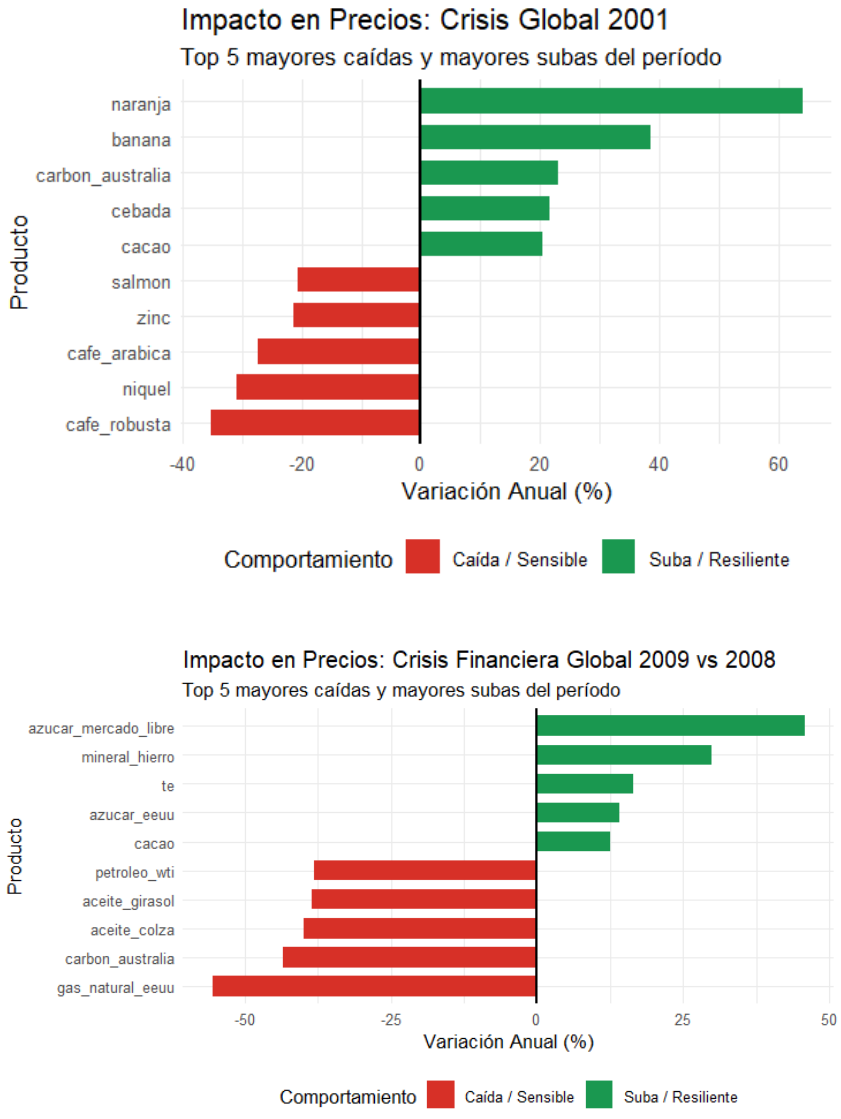


Figura 2: Top 5 de mayores caídas y subas durante las recesiones globales de 2001 y 2009.

La visualización de las variaciones extremas confirma la teoría económica subyacente. Durante la contracción de 2008/2009, los commodities ligados a la industria y la construcción (como el cobre, el mineral de hierro y el petróleo) sufrieron grandes caídas a causa del colapso en la industria a nivel global. Por otro lado, ciertos productos alimenticios exhibieron poca variación positiva, o nula, lo que demuestra su naturaleza de demanda inelástica ante caídas en el ingreso mundial, ya que son bienes sumamente necesarios.

Pregunta 3: ¿Se sostiene el comportamiento de los mercados si analizamos la correlación de sus inflaciones?

Correlacionar dos series de precios en términos nominales puede llevar a resultados desacertados si ambas comparten una tendencia a lo largo del tiempo. Correlacionar las tasas de variación interanual (inflación) nos permite ver si los verdaderos "shocks de corto plazo" están sincronizados.

Revertimos temporalmente la estructura de nuestros datos de inflación para que cada producto vuelva a ser una columna. Esto permitió aplicar nuevamente la función de correlación sobre la misma canasta de análisis de la Pregunta 1.

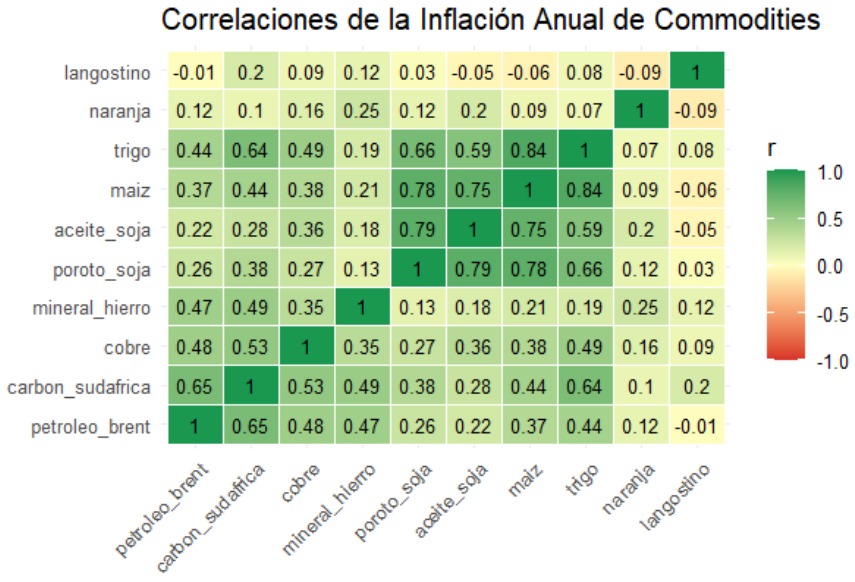


Figura 3: Matriz de correlación de las tasas de variación interanual (inflación).

Al eliminar la tendencia compartida a largo plazo, la intensidad de muchas correlaciones disminuye. Sin embargo, los vínculos más fuertes (por ejemplo, dentro del complejo sojero o energético) se mantienen altamente significativos. Esto nos permite concluir que la relación identificada en la Pregunta 1 no es simplemente un artefacto de la tendencia general de los precios a subir en el tiempo, sino que verdaderamente responden en sincronía a los shocks.

Pregunta 4: ¿Cómo evolucionó la matriz de correlaciones de precios si la evaluamos para distintos periodos (1980-1991, 1992-2003, 2004-2016)?

Las interacciones de la economía global han cambiado en los últimos años. Dividir la muestra en tercios históricos nos ayuda a identificar cambios estructurales en la forma en que operan los mercados y comprobar si las materias primas están hoy más interconectadas que en el pasado.

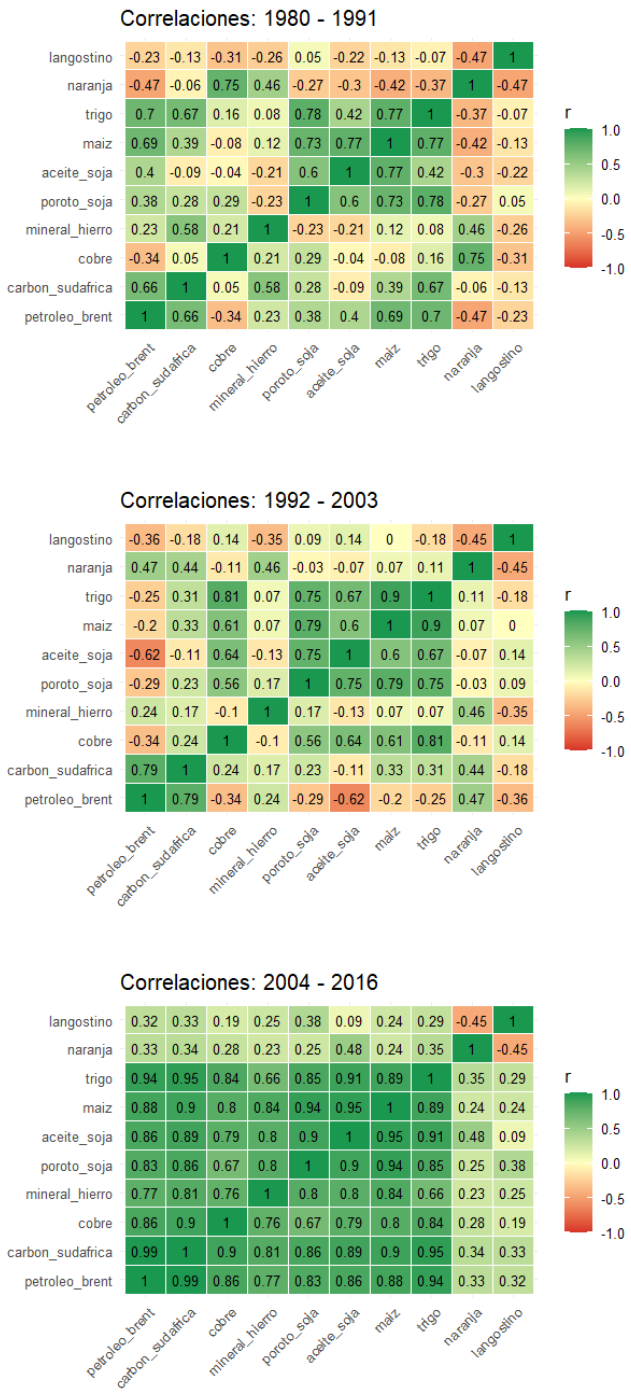


Figura 4: Evolución histórica de las matrices de correlación por períodos.

Los tres mapas de calor demuestran una evolución clara: el mapa se "oscurece" marcadamente (las correlaciones positivas se acercan a 1) durante el último período (2004-2016). Esto revela un profundo cambio estructural en los mercados, que pueden atribuirse a dos fenómenos clave de este siglo. Por un lado, el crecimiento del comercio de commodities impulsado por la integración de China a la OMC. Por otro lado, la "financiarización" de las materias primas, donde grandes fondos de inversión comenzaron a operar sobre commodities como una "clase de activo" unificada.

Ejercicio de Análisis Econométrico: Evolución del Ingreso y Determinantes de la Esperanza de Vida (Gapminder)

Para este ejercicio se utilizó el dataset Gapminder. Se realizó una limpieza inicial para asegurar que los valores faltantes fueran leídos correctamente como `NA` en R, garantizando que variables clave mantengan su formato numérico continuo y no generen errores.

Parte 1: Ingreso por Persona

Inciso 1: Evolución temporal en Argentina

Se filtraron las observaciones correspondientes a Argentina, ordenándolas cronológicamente.

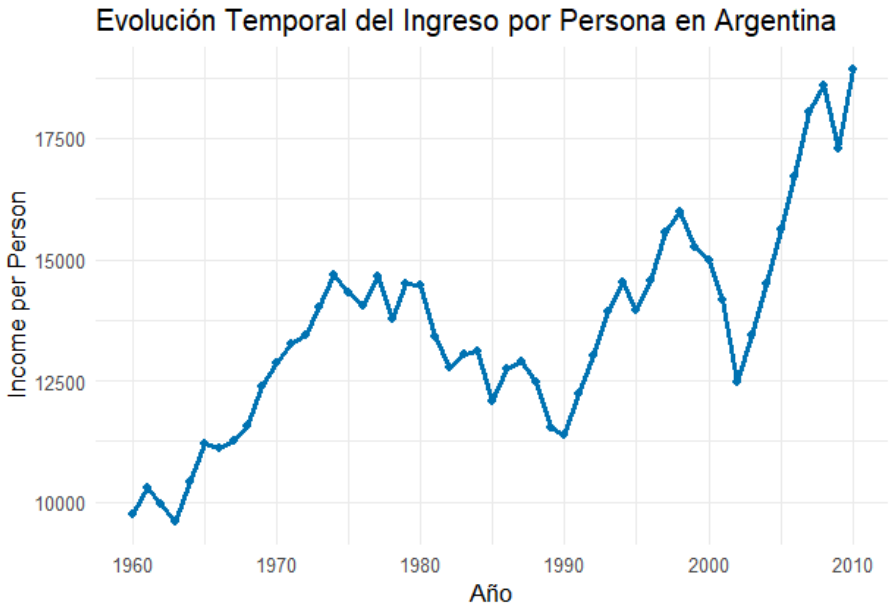


Figura 5: Evolución del ingreso por persona en Argentina (1960-2010).

La serie de tiempo muestra la trayectoria del crecimiento económico argentino a largo plazo. Confirma una tendencia general ascendente, pero fuertemente afectada por la volatilidad y las crisis cíclicas características de la historia económica del país.

Inciso 2: Modelos de Regresión y Evaluación Predictiva (Overfitting)

Se dividió la muestra separando los últimos 10 años como conjunto de prueba (Test) y el resto como entrenamiento (Train). Se centró el año inicial en cero restando el año base, es decir, lo estandarizamos.

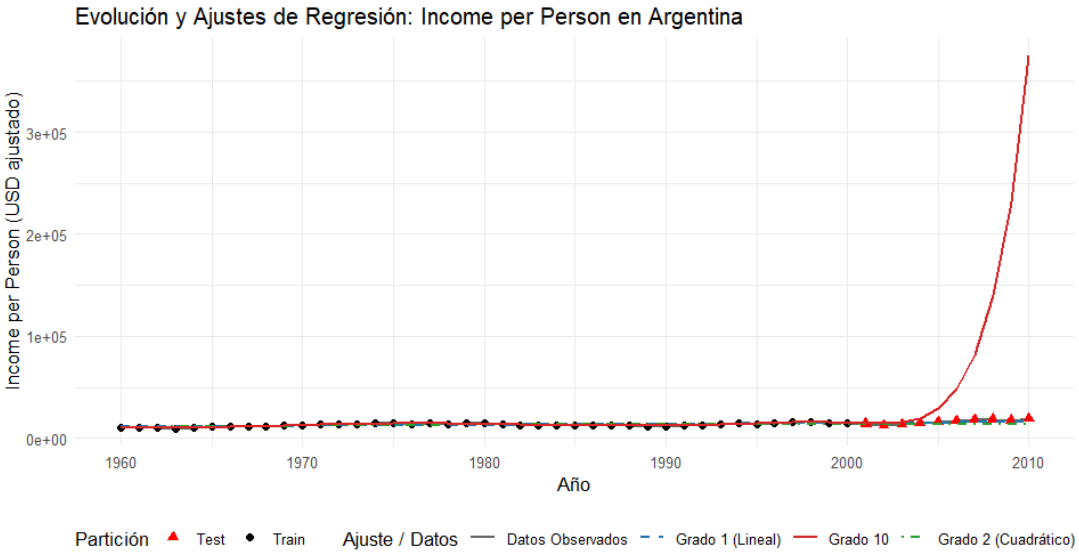


Figura 6: Ajuste de modelos polinómicos y extrapolación en el conjunto de prueba.

Tabla 4: Métricas de error por modelo polinómico

Modelo	**RMSE Train**	**RMSE Test**	**MAE Test**
Lineal	1212.75	2012.47	1769.09
Polinómico Grado 2	1159.97	3114.47	2535.31
Polinómico Grado 10	392.52	138836.75	81005.22

La evaluación ilustra un caso claro del balance entre sesgo y varianza. El modelo lineal subestima los cambios recientes. El polinomio de grado 2 captura mucho mejor la curvatura natural. Por su parte, el polinomio de grado 10 tiene el menor error dentro de la muestra de entrenamiento (se ajusta muy bien a esos datos), pero exhibe un sobreajuste extremo (*overfitting*) al llevar la predicción a los datos de prueba, donde la curva diverge exponencialmente, siendo inútil para predecir el futuro.

Inciso 3: Análisis Transversal en Sudamérica: Niveles vs. Crecimiento



Figura 7: Comparación de correlaciones en niveles vs. variaciones (tasas de crecimiento).

En niveles absolutos, se observa una correlación positiva altísima entre todos los países, resultado esperado por la tendencia de crecimiento global. Al observar las tasas de crecimiento, la conclusión es distinta. Aislar el ciclo económico mediante variaciones relativas hace que las correlaciones disminuyan, revelando asimetrías reales en cómo cada economía responde a shocks externos o internos.

Parte 2: Esperanza de Vida y Género (Año 2006)

Inciso 5: Relación Esperanza de Vida Femenina vs. General

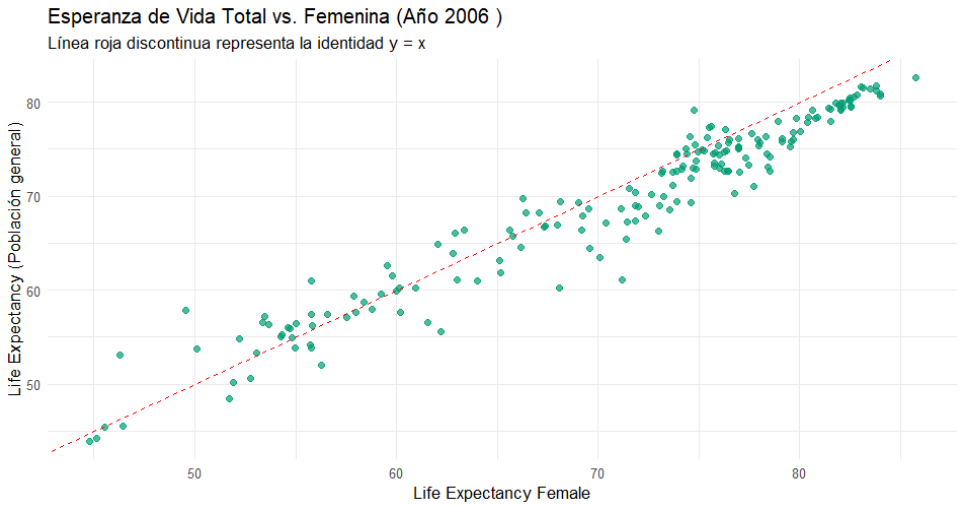


Figura 8: Gráfico de dispersión con línea de identidad ($y = x$).

Al trazar la línea de identidad a 45 grados, se observa que la mayoría de los países se sitúan por debajo y a la derecha de dicha línea. Esto comunica que la esperanza de vida femenina supera sistemáticamente al promedio general poblacional, y por transitividad, a la esperanza de vida masculina.

Inciso 6 y 7: Regresión y Test de Hipótesis Empírico

Se estimó una regresión lineal simple cuyo elevado R-cuadrado confirma la fuerte asociación lineal. Para contrastar la hipótesis nula de igualdad, se empleó un Test T pareado; las observaciones no son independientes entre sí, ya que ambas métricas provienen del mismo país y contexto en el mismo año.

Tabla 5: Regresión Simple: Esperanza General vs. Femenina

	Estimación	**Error Est.**	**Valor t**	**Pr(>|t|)**
(Intercepto)	7.0454	1.1798	5.972	1.21e-08 ***
life_expectancy_female	0.8791	0.0165	53.165	<2e-16 ***

R-cuadrado Simple: 0.9395

Tabla 6: Prueba t pareada (Paired t-test)

Métrica	**Valor**
Estadístico t	7.8138
Grados de libertad (df)	183
p-valor	2.1e-13
Hipótesis alternativa	La diferencia real de medias es mayor que 0

El p-valor prácticamente nulo lleva a rechazar la hipótesis nula. La evidencia empírica respalda, con amplia significatividad, que las mujeres viven más que el promedio de la población a nivel global.

Inciso 8: Regresión Múltiple: Controlando por el Ingreso

Se introdujo el ingreso por persona a la regresión simple del inciso anterior.

Tabla 7: Regresión Múltiple: Esperanza General vs. Femenina e Ingreso

	Estimación	**Error Est.**	**Valor t**	**Pr(>|t|)**
(Intercepto)	8.387	1.309	6.407	1.24e-09 ***
life_expectancy_female	0.8550	0.0195	43.745	<2e-16 ***
income_per_person	0.0000229	0.0000101	2.260	0.025 *

R-cuadrado Ajustado Múltiple: 0.9405

Al incorporar el nivel de ingresos, el R-cuadrado ajustado (que penaliza la inclusión innecesaria de variables) aumenta a 0.9405 frente al 0.9391 del modelo simple. El ingreso añade capacidad explicativa: un mayor nivel de desarrollo económico de un país significa una mayor cantidad de años que vive la población en promedio.

Inciso 9: Selección del Modelo Explicativo Final Propuesto

Cumpliendo la consigna, se excluyó la esperanza de vida femenina, y también se excluyó la masculina para evitar circularidad. El modelo final se construyó con tres covariables:

- **Logaritmo del Ingreso:** El ingreso tiene rendimientos marginales decrecientes sobre la salud; un leve aumento en un país pobre salva muchas vidas, pero el mismo aumento en un país rico casi no impacta.
- **Mortalidad Infantil:** Funciona como la variable más directa para medir la calidad, la cobertura y el acceso real del sistema sanitario.
- **Hijos por mujer:** Actúa como indicador del grado de transición demográfica y del desarrollo del capital humano.

Tabla 8: Modelo Explicativo Final (3 covariables)

	Estimación	**Error Est.**	**Valor t**	**Pr(>|t|)**
(Intercepto)	57.7529	4.1369	13.961	<2e-16 ***
log_income	1.8869	0.3927	4.805	3.25e-06 ***
child_mortality	-0.1520	0.0152	-9.979	<2e-16 ***
children_per_woman	0.4328	0.4118	1.051	0.295

Multiple R-squared: 0.8024, Adjusted R-squared: 0.7991

Este modelo de tres variables logra capturar razones económicas, sanitarias y demográficas de una nación.

Ejercicio de Simulación 3: Cálculo de Probabilidades y Estrategia del Envido en el Truco

Introducción y Estructuración del Entorno de Simulación

Para observar la dinámica probabilística del Truco, el primer paso fue la creación matemática del mazo. Se construyó un data frame de 40 cartas (combinando 10 valores nominales con 4 palos) utilizando la función `expand.grid()`.

Extracción Aleatoria (Incisos 1 y 2)

Sobre el mazo base, se diseñó un sistema de extracción generalizado. Se creó una función `Repartir(mazo, n_jugadores)` que extrae cartas sin reposición para un número N de jugadores de forma simultánea. Se realizaron 10.000 simulaciones de extracciones de tres cartas, calculando la media del valor facial de las cartas.

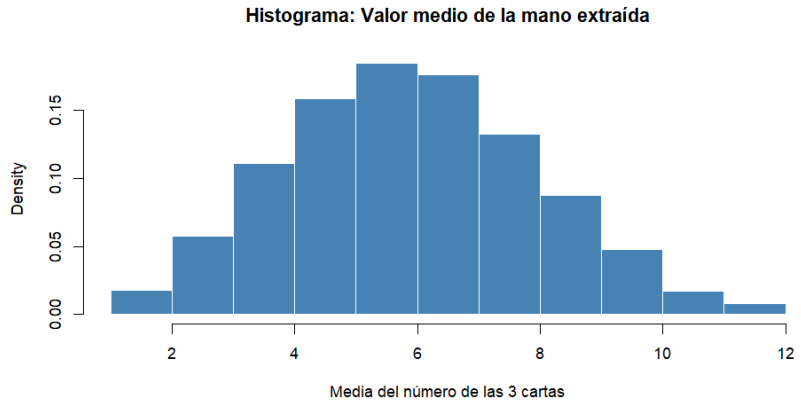


Figura 9: Distribución empírica de la media del valor de las cartas.

El histograma no refleja el puntaje de envido, sino que muestra la aleatoriedad del algoritmo de extracción. Al extraer muestras repetidas, la distribución de las medias se aproxima a una forma acampanada (Teorema del Límite Central).

Cálculo de Tantos (Inciso 3)

La función `contar_tantos()` requería cumplir con las reglas del juego. Primero, se aplicó un condicional para anular el valor de las figuras (10, 11 y 12 pasan a valer 0). Para una correcta definición, hay que tener en cuenta el caso de la "flor". Si simplemente se sumaran las cartas del palo repetido más 20, el puntaje daría un valor erróneo. Por eso, se implementó un ordenamiento decreciente que aísla y suma estrictamente las dos cartas de mayor valor de dicho palo.

Probabilidad Exacta de Perder el Envido en 1 vs 1 (Inciso 4)

La consigna exige explícitamente calcular la probabilidad exacta. Una simulación del estilo de Montecarlo hubiera sido un error. En su lugar, se utilizó la función `combn()` para generar la matriz completa de todas las combinaciones posibles. Dado que quedan 37 cartas en el mazo tras repartir nuestra mano, existen exactamente 7770 combinaciones posibles para el rival.

El código itera sobre las 7770 manos posibles, calculando sus tantos y comparándolos con los nuestros. Además, se agregó una condición para solucionar los empates (dependiendo de quién sea mano). El resultado es un cálculo probabilístico determinista y exacto.

Simulación de Partida 3 vs 3 con Probabilidad Condicional (Inciso 5)

Este escenario plantea un problema de probabilidad condicional: calcular la probabilidad de victoria dado que sabemos que nuestros dos compañeros tienen menos de 27 tantos. La función reparte cartas a los 5 jugadores restantes, pero solo contabiliza la iteración como válida si ambos compañeros cumplen la condición (< 27). El bucle iterativo garantiza que se ejecute hasta recolectar exactamente 2.000 simulaciones válidas.

Condicionar la simulación altera drásticamente las probabilidades. Al saber que nuestros compañeros tienen cartas relativamente malas para el envido, podríamos deducir que las cartas de alto valor y del mismo palo han quedado en el mazo, aumentando la probabilidad de que los jugadores del equipo rival las hayan recibido.

Distribución del Envido Rival (Inciso 6)

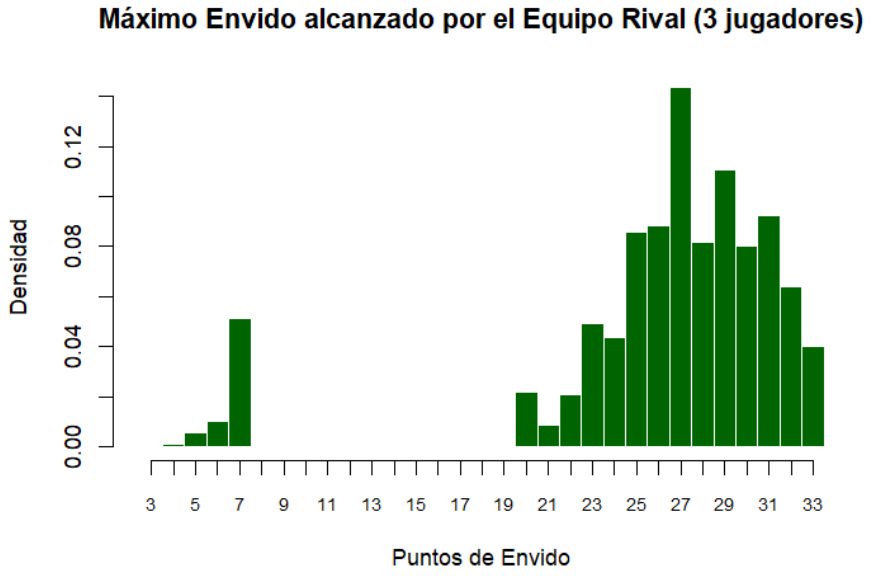


Figura 10: Distribución del mejor envido entre los 3 jugadores rivales.

El histograma revela una asimetría muy marcada hacia la derecha (valores altos). Mientras que en una partida 1 vs 1 tener 28 o 29 puntos garantiza una alta probabilidad de victoria, al enfrentarse a tres rivales, la distribución estadística se desplaza. En una mesa de 6 jugadores, la probabilidad de que al menos un rival supere la barrera de los 28 o 30 puntos es sumamente alta. Por lo tanto, si la información asimétrica revela que nuestro equipo no tiene una buena mano, la estrategia óptima dicta no aceptar envidos del equipo rival a menos que nosotros poseamos una mano excepcionalmente fuerte.